An overview of the main steps involved in analysis of data

Fase 1 : ricerca del dataset.
Dal sito dell'ISTAT ho raccolto rispettivamente il file Tavola 1.3 e Tavola 1.4
Essi rappresentano la quota di forestizzazione in Italia attraverso la sua fondazione come nazione indipendente (1861) fino al 2005.
La grandezza dei dataset è di 144 records (KEY-VALUE) : Anno → Superficie Forestale

Ho allora esplorato, prima per via qualitativa il dataset, utilizzando grafici come l'istogramma, il box plot e lo scatter plot. Come indicato nel file principale.
Ho inoltre calcolato gli indici di centralità (media, moda, mediana) e di dispersione (varianza e deviazione standard).
Ho inoltre calcolato i percentili notevoli e verificato l'assenza di outliers.
L'istogramma suggerisce riguardo alle quantità una funzione integrale che sia quadratica e quasi simmerica. Questo mi fa avanzare l'ipotesi di provare ad assegnare un coefficiente di pendenza alla funzione regressore che stia tra 0.5 e 1 in modo tale che la funzione quadratica abbia una certa inclinazione

Regressione lineare
coefficiente angolare 11880.16
intercetta 5630000

L’istogramma misura l’area sottesa al grafico. L’integrale misura l’area sottesa ad una funzione. Continuando con il ragionamento. si può associare, attraverso un passo di sostituzione nel discorso, ad ogni intervallo dell’istogramma un valore indicante l’area sottostante e quindi divenire per definizione integrale. Questa stima diventa, seguendo con il senso della stima integrale, sia il valore atteso, che la funzione di probabilità

Esempio:

Model function → y = x^2 + 0.5x

Integral Function → F(x) = 3*x^3 + x^2

Density function → Integrale (Model Function) → Integrale (x^2 + 0.5x) → Primitiva di y F(x) → (3 * x^3 + x^2) (pdf) proporzionale alla sequenza

E[X] : valore atteso → Integrale(x * pdf) → 2x^2 * (3* x ^ 3) + x^2 → 6 x^6 + 4x^4

Discesa del gradiente.
E’ una tecnica di ottimizzazione non lineare che attraverso una opportuna equazione differenziale che lega il gradiente della funzione, con il suo gradiente precedente attraverso un learning rate e un passo di intecept con gli assi.

Rispetto a quanto detto prima sulla area dei dati letti attraverso le lenti dell’istogramma, ho utilizzato non soltanto tecniche integrali, ma anche i loro opposti come qui rilevo ossia i metodi di ottimizzazione.
Ho utilizzato la tecnica di discesa del gradiente per verificare dove stia il minimo locale del regressore attraverso le iterazione di ricombinazione lineare attraverso learning rate e passo di spiazzamento come da discesa del gradiente

Discesa del gradiente.
L’algoritmo stima nel punto -0.25, 0,0625, che è una misura robusta, in quanto verificata nel seguente modo.
Sia $f(x) = x^2 + 0.5x$
con $x = -0.25 \rightarrow 0.1125$
Nota bene: e’ il minimo della funzione regressore, non è il minimo del trend italiano boschivo. Difatti vicino ai primi valori di accumulo la parabola sembra porsi bene per tale fenomeno al ribasso, mentre si mostra piu’ che affidabile e robusta nella regressione ai valori di campione

Problema del regressore rimasto ancora aperto.
Nonostante i residui tra regressore e valore del campione siano ben accetti per un buon fit di dati, riesce difficile ancorare il trend boschivo ad una funzione a crescita rapida come la parabolica e la lineare. Deduco quindi un problema di overfitting dei dati ossia eccessivamente precisi da potersi generalizzare

Si vuole allora provare ad effettuare un clustering sui dati campionari per identificare clusters di dati omogenei.
Attraverso un grafico a plot della intertia, la quale misura la variabilità totale all'interno di un set di dati, essa misura quindi il coefficiente di omogeneità e disomogenità rispetto agli altri cluster, sulla quale è calcolata.

Si evidenziano tre clusters tra : 1860-1920 e 1940 e 1960, 1921,1940 e 1961-1980, 1980,2000, ciascuno indicante una pecularie rapidità di crescita.
Si può quindi intuire che vi siano da stimare tre funzioni a seconda del cluster con una data monotonia e continuità.
Occorre inoltre eliminare i punti di discontinuità di prima specie, in modo tale che le funzioni siano analiticamente studiabili

Sarà quindi calcolato per ogni cluster i summary indexes.

Boostrapping
Lo ho utilizzato a partire dai cluster dei dati, produrre un resampling di questi vericando quanto siano robusti i dati rispetto al campione estratto